模块四 成对数据的统计分析

第 1 节 一元线性回归模型及其应用 (★★★)

强化训练

- 1. (2023 •河南模拟 •★) 为了研究汽车减重对降低油耗的作用,对一组样本数据 $(x_1,y_1),(x_2,y_2),\cdots,(x_n,y_n)$ 进行分析,其中 x_i 表示减重质量(单位: kg), y_i 表示每行驶一百公里降低的油耗(单位: 升), $i=1,2,\cdots,n$, 由此得到的经验回归方程为 $\hat{y} = \hat{b}x + \hat{a}(\hat{b} > 0)$,有下列四个说法:
- ① \hat{a} 的值一定为 0; ② \hat{b} 越大,减重对降低油耗的作用越大; ③决定系数 R^2 越大,拟合效果越好; ④至少 有一个数据点在经验回归直线上. 其中所有正确说法的编号是()
 - (A) (1)(4)
- (B) 23 (C) 234
- (D) (1)(2)(4)

答案: B

解析:①项,从实际意义来看,a表示减重 0kg 时,每行驶一百公里降低的油耗,应该为 0,但 \hat{a} 是由样本 观测数据求出的 a 的估计值,只会近似等于 0,但不是一定为 0,故①项错误;

- ②项, \hat{b} 越大,则每减重 1kg,行驶一百公里降低的油耗越多,减重对降低油耗的作用越大,故②项正确;
- ③项,决定系数 \mathbb{R}^2 越大,则残差平方和越小,拟合效果越好,故③项正确;
- ④项,用最小二乘法估计经验回归方程,数据点不一定落在经验回归直线上,故④项错误.
- 2. $(2023 \cdot 湖南模拟 \cdot ★)(多选)设某大学的女生体重<math>y$ (单位: kg)与身高x(单位: cm)具有线性相 关关系,根据一组样本数据 $(x_i, y_i)(i=1,2,\dots,n)$,用最小二乘法建立的经验回归方程为 $\hat{y}=0.85x-85.71$, 则下列结论中正确的是()
 - (A) y 与 x 有正的线性相关关系
 - (B) 若该大学女生的平均身高为 168cm,则平均体重约为 57.09kg
 - (C) 若该大学某女生身高增加 1cm,则其体重约增加 0.85kg
 - (D) 若该大学某女生身高为 170cm,则可断定其体重必为 58.79kg

答案: ABC

解析: A 项, 经验回归直线的斜率 $\hat{b}=0.85>0$, 所以y与x正相关,故A 项正确;

- B 项,当x = 168 时, $\hat{y} = 0.85 \times 168 85.71 = 57.09$,所以平均体重约为 57.09kg,故 B 项正确;
- \mathbb{C} 项,因为 $\hat{b}=0.85$,所以当女生身高增加 1cm 时,其体重约增加 0.85kg,故 \mathbb{C} 项正确;
- D项,看到题干的"其体重必为58.79kg",即可得出D选项错误,因为只能说"其体重约为58.79kg".
- 3.(2023•宁夏吴忠模拟• $\star\star$)某种产品的广告费用x(单位:万元)与销售额y(单位:万元)之间的 关系如下表,若y与x的经验回归方程为 $\hat{y}=1.3x+m$,则m=()

$\boldsymbol{\mathcal{X}}$	1	3	4	5	7
y	6	8	12	10	14

(A) 4.1 (B) 4.7 (C) 4.8 (D) 6.8

答案: C

解析: 经验回归方程中只有m未知,可将样本中心点(x,y)代入,

曲题意,
$$\bar{x} = \frac{1+3+4+5+7}{5} = 4$$
, $\bar{y} = \frac{6+8+12+10+14}{5} = 10$,

将 (4,10)代入 $\hat{y}=1.3x+m$ 可得 $10=1.3\times4+m$, 所以 m=4.8.

4. (2023•吉林模拟•★★) 某地以"绿水青山就是金山银山"理念为引导,推进绿色发展,现要订购一 批苗木,苗木长度与售价如下表:

苗木长度 x (cm)	38	48	58	68	78	88
售价 y (元)	16.8	18.8	20.8	22.8	24	25.8

若苗木长度 x(cm)与售价 y(元)之间存在线性相关关系,其经验回归方程为 $\hat{y} = \hat{b}x + 8.9$,则当售价大 约为38.9元时,苗木长度大约为()

(A) 148cm

(B) 150cm (C) 152cm

(D) 154cm

答案: B

解析:应先由表中数据求出 \hat{b} ,才能作出估计,可将样本中心点 (\bar{x},\bar{y}) 代入经验回归方程,

曲题意,
$$\bar{x} = \frac{38 + 48 + 58 + 68 + 78 + 88}{6} = 63$$
, $\bar{y} = \frac{16.8 + 18.8 + 20.8 + 22.8 + 24 + 25.8}{6} = 21.5$,

将 (63,21.5)代入 $\hat{y} = \hat{b}x + 8.9$ 可得 $21.5 = 63\hat{b} + 8.9$,解得: $\hat{b} = 0.2$,所以 $\hat{y} = 0.2x + 8.9$,

当 \hat{y} = 38.9 时,38.9 = 0.2x + 8.9 ,解得: x = 150 ,所以当售价大约为38.9 元时,苗木长度大约为150cm.

5. (2022•贵州模拟•★★★) 某企业新研发了一种产品,产品的成本由原料成本及非原料成本组成,每 件产品的非原料成本y(元)与生产的产品数量x(千件)有关,经统计得到如下数据:

- (1) 根据表中的数据,运用相关系数进行分析说明,可以用一元线性回归模型拟合y与x的关系,并指出 是正相关还是负相关;
- (2) 求y关于x的经验回归方程,并预测生产该产品 13 千件时,每件产品的非原料成本为多少元?

参考公式: 相关系数
$$r = \frac{\displaystyle\sum_{i=1}^{n}(x_{i}-\overline{x})(y_{i}-\overline{y})}{\sqrt{\displaystyle\sum_{i=1}^{n}(x_{i}-\overline{x})^{2}}\cdot\sqrt{\displaystyle\sum_{i=1}^{n}(y_{i}-\overline{y})^{2}}}$$
, 经验回归方程 $\hat{y}=\hat{b}x+\hat{a}$ 中的 \hat{b} 和 \hat{a} 的最小二乘估计

公式为
$$\hat{b} = \frac{\sum_{i=1}^{n} (x_i - \overline{x})(y_i - \overline{y})}{\sum_{i=1}^{n} (x_i - \overline{x})^2}$$
, $\hat{a} = \overline{y} - \hat{b}\overline{x}$; 参考数据: $\sqrt{2} \approx 1.414$.

 \mathbf{m} : (1)(直接代给出的相关系数公式求 r 可行,但注意到数据的绝对值都不大,按

$$r = \frac{\sum_{i=1}^{n} x_{i} y_{i} - n \overline{x} \overline{y}}{\sqrt{(\sum_{i=1}^{n} x_{i}^{2} - n \overline{x}^{2}) \cdot (\sum_{i=1}^{n} y_{i}^{2} - n \overline{y}^{2})}}$$
来算更方便,先求 \overline{x} 和 \overline{y})

由表中数据可得,
$$\bar{x} = \frac{2+5+8+9+11}{5} = 7$$
, $\bar{y} = \frac{12+10+8+8+7}{5} = 9$,

所以
$$\sum_{i=1}^{5} (x_i - \overline{x})(y_i - \overline{y}) = \sum_{i=1}^{5} x_i y_i - 5\overline{x}\overline{y} = 2 \times 12 + 5 \times 10 + 8 \times 8 + 9 \times 8 + 11 \times 7 - 5 \times 7 \times 9 = -28$$
,

$$\sum_{i=1}^{5} (x_i - \overline{x})^2 = \sum_{i=1}^{5} x_i^2 - 5\overline{x}^2 = 2^2 + 5^2 + 8^2 + 9^2 + 11^2 - 5 \times 7^2 = 50,$$

$$\sum_{i=1}^{5} (y_i - \overline{y})^2 = \sum_{i=1}^{5} y_i^2 - 5\overline{y}^2 = 12^2 + 10^2 + 8^2 + 8^2 + 7^2 - 5 \times 9^2 = 16,$$

故相关系数
$$r = \frac{\sum_{i=1}^{5} (x_i - \overline{x})(y_i - \overline{y})}{\sqrt{\sum_{i=1}^{5} (x_i - \overline{x})^2} \cdot \sqrt{\sum_{i=1}^{5} (y_i - \overline{y})^2}} = \frac{-28}{\sqrt{50} \times \sqrt{16}} = -\frac{7}{5\sqrt{2}} \approx -\frac{7}{5 \times 1.414} \approx -0.99$$

因为|r|很接近 1,所以 x,y 的线性相关性很强,可用一元线性回归模型拟合 y 与 x 的关系,又 r < 0 ,所以 y 与 x 负相关.

所以y关于x的经验回归方程为 $\hat{y}=-0.56x+12.92$,当x=13时, $\hat{y}=-0.56\times13+12.92=5.64$,故可预测生产该产品 13 千件时,每件产品的非原料成本约为 5.64 元.

【反思】若观测数据
$$x_i$$
, y_i 的绝对值较小,则按 $\sum_{i=1}^n x_i y_i - n \overline{x} \overline{y}$, $\sum_{i=1}^n x_i^2 - n \overline{x}^2$, $\sum_{i=1}^n y_i^2 - n \overline{y}^2$ 来算比按

$$\sum_{i=1}^{n} (x_i - \overline{x})(y_i - \overline{y})$$
, $\sum_{i=1}^{n} (x_i - \overline{x})^2$, $\sum_{i=1}^{n} (y_i - \overline{y})^2$ 计算简单,否则宜采用后者计算.

6. (2023 · 江苏泰州模拟 · ★★★) 小家电指除大功率、大体积家用电器(如冰箱、洗衣机、空调等) 以外的家用电器,运用场景广泛,近年来随着科技发展,智能小家电市场规模呈持续发展趋势,下表为连续5年中国智能小家电市场规模(单位:千亿元),其中年份对应的代码依次为1~5.

- (1) 由上表数据可知,可用线性回归模型拟合y与x的关系,请用相关系数加以说明;
- (2) 建立y 关于x 的经验回归方程.

参考数据:
$$\overline{y} = 1.32$$
, $\sum_{i=1}^{5} x_i y_i = 21.4$, $\sqrt{\sum_{i=1}^{5} (y_i - \overline{y})^2} \approx 0.55$, $\sqrt{10} \approx 3.16$;

参考公式: 相关系数
$$r = \frac{\displaystyle\sum_{i=1}^{n}(x_{i}-\overline{x})(y_{i}-\overline{y})}{\sqrt{\displaystyle\sum_{i=1}^{n}(x_{i}-\overline{x})^{2}}\cdot\sqrt{\displaystyle\sum_{i=1}^{n}(y_{i}-\overline{y})^{2}}}$$
, 经验回归方程 $\hat{y}=\hat{b}x+\hat{a}$ 中的 \hat{b} 和 \hat{a} 的最小二乘估计

公式分别为
$$\hat{b} = \frac{\sum_{i=1}^{n} (x_i - \overline{x})(y_i - \overline{y})}{\sum_{i=1}^{n} (x_i - \overline{x})^2}$$
, $\hat{a} = \overline{y} - \hat{b}\overline{x}$.

解: (1) (观察所给公式发现求相关系数 r, 还差 $\sum_{i=1}^{5} (x_i - \bar{x})^2$ 和 $\sum_{i=1}^{5} (x_i - \bar{x})(y_i - \bar{y})$, 故分别计算)

曲题意,
$$\overline{x} = \frac{1+2+3+4+5}{5} = 3$$
,所以 $\sum_{i=1}^{5} (x_i - \overline{x})^2 = (1-3)^2 + (2-3)^2 + (3-3)^2 + (4-3)^2 + (5-3)^2 = 10$,

(再算
$$\sum_{i=1}^{5} (x_i - \bar{x})(y_i - \bar{y})$$
, 参考数据中有 $\sum_{i=1}^{5} x_i y_i$, 故转化为 $\sum_{i=1}^{5} x_i y_i - 5\bar{x}\bar{y}$ 来算)

$$\sum_{i=1}^{5} (x_i - \overline{x})(y_i - \overline{y}) = \sum_{i=1}^{5} x_i y_i - 5\overline{x} \, \overline{y} = 21.4 - 5 \times 3 \times 1.32 = 1.6 \,,$$

所以
$$r = \frac{\sum_{i=1}^{5} (x_i - \overline{x})(y_i - \overline{y})}{\sqrt{\sum_{i=1}^{5} (x_i - \overline{x})^2} \cdot \sqrt{\sum_{i=1}^{5} (y_i - \overline{y})^2}} \approx \frac{1.6}{\sqrt{10} \times 0.55} \approx \frac{1.6}{3.16 \times 0.55} \approx 0.92,$$

故 y 与 x 的线性相关程度较高,可用线性回归模型拟合 y 与 x 的关系.

(2) (算
$$\hat{b}$$
需要用到的数据都有了,故直接计算)由(1)可得 $\hat{b} = \frac{\sum_{i=1}^{5} (x_i - \overline{x})(y_i - \overline{y})}{\sum_{i=1}^{5} (x_i - \overline{x})^2} = \frac{1.6}{10} = 0.16$,

 $\hat{a} = \overline{y} - \hat{b}\overline{x} = 1.32 - 0.16 \times 3 = 0.84$,所以y关于x的经验回归方程为 $\hat{y} = 0.16x + 0.84$.

- 7.(2023·江苏苏州模拟·★★★)新能源汽车作为战略新兴产业,代表汽车产业的发展方向,发展新能源汽车,对改善能源消费结构、减少空气污染、推动汽车产业和交通运输业转型升级具有积极意义,经过十多年的精心培育,我国新能源汽车产业取得了显著成绩,产销量连续四年全球第一,保有量居全球首位.
- (1) 已知某公司生产的新能源汽车电池的使用寿命 ξ (单位:万公里)服从正态分布N(60,16),问:该公司每月生产的2万块电池中,大约有多少块电池的使用寿命可以超过68万公里?

参考数据: 若随机变量 $\xi \sim N(\mu, \sigma^2)$,则 $P(\mu - \sigma < \xi < \mu + \sigma) \approx 0.683$, $P(\mu - 2\sigma < \xi < \mu + 2\sigma) \approx 0.955$, $P(\mu - 3\sigma < \xi < \mu + 3\sigma) \approx 0.997$.

(2) 下表给出了我国 2017~2021 年新能源汽车保有量 y (单位: 万辆)的数据.

年份	2017	2018	2019	2020	2021
年份代码 x	1	2	3	4	5
新能源汽车保有量y	153	260	381	492	784

经计算,变量 x, y 的样本相关系数 $r_1 \approx 0.946$,变量 x^2 与 y 的样本相关系数 $r_2 \approx 0.985$.

- ①试判断 $\hat{y} = \hat{b}x + \hat{a}$ 和 $\hat{y} = \hat{b}x^2 + \hat{a}$ 哪一个更适合作为 y 与 x 之间的回归模型?
- ②根据①的判断结果,求出 y 关于 x 的回归方程 (精确到 0.1),并预测 2023 年我国新能源汽车的保有量.

参考数据: 令
$$t_i = x_i^2 (i = 1, 2, 3, 4, 5)$$
,计算得 $\overline{y} = 414$, $\sum_{i=1}^5 x_i y_i = 7704$, $\sum_{i=1}^5 t_i y_i = 32094$, $\sum_{i=1}^5 t_i^2 = 979$.

参考公式: 在回归方程
$$\hat{y} = \hat{b}x + \hat{a}$$
中, $\hat{b} = \frac{\sum_{i=1}^{n} x_i y_i - n \overline{x} \overline{y}}{\sum_{i=1}^{n} x_i^2 - n \overline{x}^2}$, $\hat{a} = \overline{y} - \hat{b} \overline{x}$.

解: (1) 因为 $\xi \sim N(60,16)$,该正态分布的均值 $\mu = 60$,标准差 $\sigma = 4$,

所以
$$P(\xi > 68) = P(\xi > \mu + 2\sigma) = \frac{1 - P(\mu - 2\sigma < \xi < \mu + 2\sigma)}{2} \approx \frac{1 - 0.955}{2} = 0.0225$$

故该公司每月生产的 2 万块电池中,使用寿命可以超过 68 万公里的块数约为 20000×0.0225 = 450.

(2) ①因为 $r_1 \approx 0.946$, $r_2 \approx 0.985$,所以 $|r_2| > |r_1|$,故 $\hat{y} = \hat{b}x^2 + \hat{a}$ 更适合作为y与x之间的回归模型.

②令 $t=x^2$,则 $\hat{y}=\hat{b}x^2+\hat{a}$ 即为 $\hat{y}=\hat{b}t+\hat{a}$,(y 关于 t 为线性回归模型,可用最小二乘估计公式求 \hat{b} 和 \hat{a})

曲题意,
$$\overline{t} = \frac{t_1 + t_2 + \dots + t_5}{5} = \frac{x_1^2 + x_2^2 + \dots + x_5^2}{5} = \frac{1^2 + 2^2 + \dots + 5^2}{5} = 11$$

结合参考数据可得
$$\hat{b} = \frac{\sum_{i=1}^{5} t_i y_i - 5\overline{t} \, \overline{y}}{\sum_{i=1}^{5} t_i^2 - 5\overline{t}^2} = \frac{32094 - 5 \times 11 \times 414}{979 - 5 \times 11^2} = \frac{9324}{374} \approx 24.9$$
, $\hat{a} = \overline{y} - \hat{b}\overline{t} = 414 - \frac{9324}{374} \times 11 \approx 139.8$,

所以y关于t的回归方程为 $\hat{y}=24.9t+139.8$,故y关于x的回归方程为 $\hat{y}=24.9x^2+139.8$,

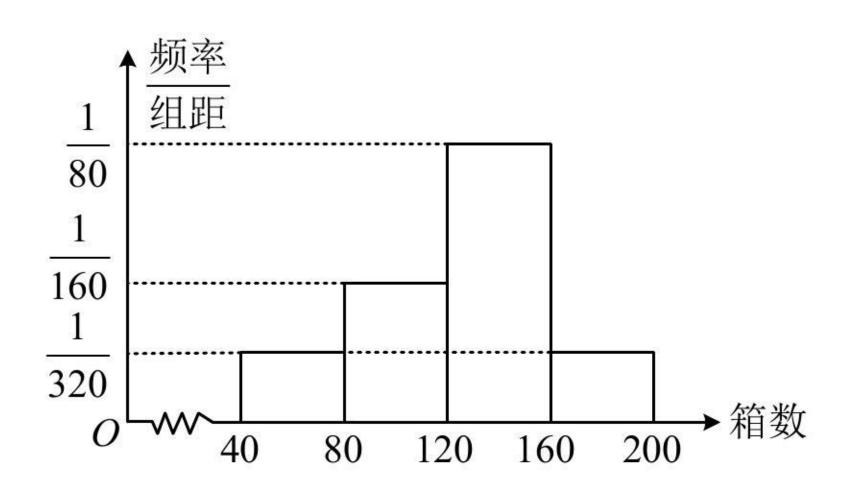
当x=7时, $\hat{y}=24.9\times7^2+139.8=1359.9$,所以预测 2023 年我国新能源汽车的保有量约为 1359.9 万辆.

【**反思**】上述求 \hat{a} 的过程中,若把 \hat{b} 代成近似后的数据 24.9,则求得的 \hat{a} 为 140.1,此时 2023 年我国新能源汽车的保有量的预测值则为 1360.2 万辆,这一结果也算正确.

8.(2023•湖南长沙雅礼中学模拟•★★★★)为贯彻中共中央、国务院 2023 年一号文件,某单位在当地定点帮扶某村种植一种草莓,并把这种露天种植的草莓搬到了大棚里,收到了很好的经济效益. 根据资料显示,产出的草莓的箱数x(单位:箱)与成本y(单位:千元)的关系如下:

可用回归方程 $\hat{y} = \hat{b} \lg x + \hat{a}$ (其中 \hat{a} , \hat{b} 为常数)来拟合y与x的关系.

- (1) 若农户卖出该草莓的价格为 150 元/箱, 试预测该草莓 100 箱的利润是多少元; (利润=售价-成本)
- (2) 据统计,1 月份的连续 16 天中农户每天为甲地可配送的该草莓的箱数的频率分布直方图如图,用这 16 天的情况来估计相应的概率. 一个运输户拟购置 n 辆小货车专门运输农户为甲地配送的该草莓,一辆货车每天只能运一趟,每辆车每趟最多只能装载 40 箱该草莓,满载发车,否则不发车. 若发车,则每辆车每趟可获利 500 元; 若未发车,则每辆车每天平均亏损 200 元. 试比较 n=3 和 n=4 时,此项业务每天的利润平均值的大小.



参考数据与公式: 线性回归直线 $\hat{y} = \hat{b}t + \hat{a}$ 中, $\hat{b} = \frac{\sum_{i=1}^{n} (t_i - \overline{t})(y_i - \overline{y})}{\sum_{i=1}^{n} (t_i - \overline{t})^2}$, $\hat{a} = \overline{y} - \hat{b}\overline{t}$; 设 $t = \lg x$, 则

\overline{t}	\overline{y}	$\sum_{i=1}^{5} (t_i - \overline{t})(y_i - \overline{y})$	$\sum_{i=1}^{5} (t_i - \overline{t})^2$
0.54	6.8	1.53	0.45

解: (1) (先求 100 箱草莓的成本,需建立y关于x的回归方程,题干已经作了变换 $t = \lg x$,故直接求 \hat{b} 和 \hat{a})

曲题意,
$$\hat{b} = \frac{\sum_{i=1}^{5} (t_i - \overline{t})(y_i - \overline{y})}{\sum_{i=1}^{5} (t_i - \overline{t})^2} = \frac{1.53}{0.45} = 3.4$$
, $\hat{a} = \overline{y} - \hat{b}\overline{t} = 6.8 - 3.4 \times 0.54 = 4.964$,

所以y关于t的回归方程为 $\hat{y}=3.4t+4.964$,又 $t=\lg x$,所以y关于x的回归方程为 $\hat{y}=3.4\lg x+4.964$,从 而 当 x=100 时 , $\hat{y}=3.4\lg 100+4.964=11.764$, 故 可 预 测 该 草 莓 100 箱 的 利 润 为 $100\times150-11.764\times1000=3236$ 元.

(2)(利润受每辆车是否发车影响,每辆车是否发车又由可配送的草莓箱数决定,箱数为随机变量,由频率分布直方图可获得其概率分布,从而得到利润的概率分布,下面分别考虑)

设该草莓可配送的箱数为随机变量 X,由频率分布直方图可知 X 的概率分布如下表:

X	[40,80)	[80,120)	[120,160)	[160, 200]
D	1	1	1	1
	$\frac{\overline{8}}{8}$	$\frac{\overline{4}}{4}$	$\overline{2}$	$\frac{\overline{8}}{8}$

当n=3时,设此项业务的利润为Y,则当40 ≤ X < 80时,只能发 1 辆车,

此时
$$Y = 500 - 2 \times 200 = 100$$
,所以 $P(Y = 100) = \frac{1}{8}$,

当 $80 \le X < 120$ 时,可发 2 辆车,此时 $Y = 500 \times 2 - 200 = 800$,所以 $P(Y = 800) = \frac{1}{4}$,

当 $120 \le X \le 200$ 时,可发 3 辆车,此时 $Y = 500 \times 3 = 1500$,所以 $P(Y = 1500) = \frac{1}{2} + \frac{1}{8} = \frac{5}{8}$,

故
$$E(Y) = 100 \times \frac{1}{8} + 800 \times \frac{1}{4} + 1500 \times \frac{5}{8} = 1150$$
;

当n=4时,设此项业务的利润为Z,则当 $40 \le X < 80$ 时,只能发 1 辆车,

此时 $Z=500-3\times200=-100$,所以 $P(Z=-100)=\frac{1}{8}$, 当 $80 \le X < 120$ 时,可发 2 辆车,此时 $Z=500\times2-200\times2=600$,所以 $P(Z=600)=\frac{1}{4}$, 当 $120 \le X < 160$ 时,可发 3 辆车,此时 $Z=500\times3-200=1300$,所以 $P(Z=1300)=\frac{1}{2}$, 当 $160 \le X \le 200$ 时,可发 4 辆车,此时 $Z=500\times4=2000$,所以 $P(Z=2000)=\frac{1}{8}$, 故 $E(Z)=-100\times\frac{1}{8}+600\times\frac{1}{4}+1300\times\frac{1}{2}+2000\times\frac{1}{8}=1037.5$; 因为 E(Z)<E(Y),所以购置 3 辆小货车此项业务的平均利润更大.

《一数•高考数学核心方法》